

INFORME COMPARATIVO: PARADIGMAS DE APRENDIZAJE AUTOMÁTICO EN MARKETING DIGITAL



Análisis de Implementación y Resultados

20 de abril de 2025

Índice

1. RESUMEN EJECUTIVO	2
2. INTRODUCCIÓN	2
3. METODOLOGÍA E IMPLEMENTACIÓN	2
3.1. Base de Datos y Contexto	2
3.2. Aprendizaje Supervisado	3
3.3. Aprendizaje No Supervisado	3
3.4. Aprendizaje por Refuerzo	3
4. RESULTADOS Y ANÁLISIS	4
4.1. Aprendizaje Supervisado	4
4.1.1. Matriz de Confusión	4
4.1.2. Métricas de Rendimiento	4
4.1.3. Coeficientes del Modelo	4
4.1.4. Interpretación	4
4.2. Aprendizaje No Supervisado	4
4.2.1. Método del Codo	4
4.2.2. Segmentación Obtenida	5
4.2.3. Visualización Espacial	5
4.2.4. Interpretación	5
4.3. Aprendizaje por Refuerzo	5
4.3.1. Evolución del Aprendizaje	5
4.3.2. Distribución de Acciones	5
4.3.3. Estrategias por Segmento	6
4.3.4. Rendimiento Comparativo	6
4.3.5. Interpretación	6
5. ANÁLISIS COMPARATIVO DE PARADIGMAS	6
5.1. Matriz Comparativa	6
5.2. Complementariedad Funcional	7
5.3. Progresión Analítica	7
5.4. Integración Sinérgica	7
6. IMPLICACIONES ESTRATÉGICAS Y COMERCIALES	8
6.1. Derivadas del Aprendizaje Supervisado	8
6.2. Derivadas del Aprendizaje No Supervisado	8
6.3. Derivadas del Aprendizaje por Refuerzo	8
6.4. Integración Estratégica	9
7. CONCLUSIONES Y RECOMENDACIONES	9
7.1. Hallazgos Principales	9
7.2. Recomendaciones	9
7.3. Consideraciones Finales	10
ANEXO: GLOSARIO TÉCNICO	11

1 RESUMEN EJECUTIVO

El presente informe analiza la implementación y los resultados de los tres paradigmas fundamentales del aprendizaje automático (supervisado, no supervisado y por refuerzo) aplicados a un caso de estudio de marketing digital. Cada enfoque aborda diferentes aspectos complementarios del comportamiento del usuario: predicción de conversiones, segmentación de clientes y optimización de estrategias de interacción. Los resultados demuestran el valor diferencial de cada paradigma, así como su potencial sinérgico cuando se implementan de manera integrada. El aprendizaje supervisado alcanzó un área bajo la curva ROC de 0,79 para la predicción de compras; el aprendizaje no supervisado identificó cuatro segmentos de usuarios claramente diferenciados; y el aprendizaje por refuerzo logró una mejora del 378 % en las recompensas frente a estrategias aleatorias. Esta implementación integral proporciona un marco analítico holístico que combina capacidades descriptivas, predictivas y prescriptivas para optimizar la experiencia del usuario y maximizar conversiones.

2 INTRODUCCIÓN

La transformación digital del sector comercial ha generado volúmenes sin precedentes de datos sobre comportamiento de usuarios. El aprovechamiento eficaz de esta información requiere enfoques analíticos sofisticados que proporcionen no solo comprensión retrospectiva, sino también capacidad predictiva y prescriptiva. Este informe examina la implementación de los tres paradigmas fundamentales del aprendizaje automático en un contexto de e-commerce:

- **Aprendizaje Supervisado:** Enfocado en predecir la probabilidad de conversión a partir de patrones de navegación.
- **Aprendizaje No Supervisado:** Orientado a descubrir segmentos naturales de usuarios según su comportamiento.
- **Aprendizaje por Refuerzo:** Dirigido a optimizar estrategias de marketing contextuales para maximizar conversiones.

Para cada paradigma, se analizan su fundamento teórico, implementación técnica, resultados obtenidos e implicaciones estratégicas, culminando con una evaluación comparativa de sus fortalezas complementarias.

3 METODOLOGÍA E IMPLEMENTACIÓN

3.1 Base de Datos y Contexto

Se generaron datos sintéticos que simulan el entorno de un comercio electrónico, incluyendo:

- Métricas de navegación (tiempo en sitio, páginas visitadas)
- Historial de interacciones previas
- Eventos de conversión (compras)
- Segmentos de usuarios con diferentes perfiles de comportamiento
- Acciones de marketing y sus resultados asociados

3.2 Aprendizaje Supervisado

Objetivo: Predecir la probabilidad de compra basada en comportamiento observable.

Técnica implementada: Regresión logística con características estandarizadas.

Variables predictoras:

- Tiempo en sitio
- Páginas visitadas
- Historial de clics previos

Proceso:

1. División de datos en conjuntos de entrenamiento (70 %) y prueba (30 %)
2. Normalización de variables predictoras
3. Entrenamiento del modelo logístico
4. Evaluación mediante matriz de confusión y curva ROC

3.3 Aprendizaje No Supervisado

Objetivo: Identificar segmentos naturales de usuarios con comportamientos similares.

Técnica implementada: Algoritmo K-Means con cuatro clusters.

Variables utilizadas:

- Características multidimensionales de comportamiento y preferencias

Proceso:

1. Determinación del número óptimo de clusters mediante método del codo
2. Aplicación de K-Means con $k=4$
3. Caracterización de los segmentos identificados
4. Análisis comparativo de perfiles comportamentales por cluster

3.4 Aprendizaje por Refuerzo

Objetivo: Optimizar estrategias de marketing contextualmente relevantes.

Técnica implementada: Q-Learning con política epsilon-greedy y decaimiento de exploración.

Componentes del entorno:

- **Estados:** Combinaciones de segmento de usuario, historial y nivel de interés
- **Acciones:** Cinco estrategias de marketing diferentes
- **Recompensas:** Valoración cuantitativa del éxito de cada acción según contexto

Proceso:

1. Inicialización de tabla Q con valores cero
2. Entrenamiento durante 10.000 episodios con decaimiento de exploración
3. Evaluación comparativa frente a política aleatoria
4. Análisis de estrategias óptimas por segmento

4 RESULTADOS Y ANÁLISIS

4.1 Aprendizaje Supervisado

4.1.1 Matriz de Confusión

La matriz de confusión revela un desbalance significativo con predominancia de predicciones positivas:

- Verdaderos Positivos: 227
- Verdaderos Negativos: 21
- Falsos Positivos: 39
- Falsos Negativos: 13

4.1.2 Métricas de Rendimiento

- Accuracy: 0,827
- Precision: 0,853
- Recall: 0,946
- F1-Score: 0,897
- ROC AUC: 0,786

4.1.3 Coeficientes del Modelo

- Tiempo en sitio: 0,999 (Positivo)
- Páginas visitadas: 0,979 (Positivo)
- Historial de clics: 0,642 (Positivo)

4.1.4 Interpretación

El modelo supervisado muestra una capacidad notable para identificar compradores potenciales, con especial énfasis en minimizar falsos negativos. El tiempo en sitio y las páginas visitadas emergen como los predictores más potentes, mientras que el historial de clics aporta información complementaria. La elevada tasa de recall (94,6 %) resulta particularmente valiosa en contextos donde identificar oportunidades de venta constituye una prioridad sobre la precisión absoluta.

4.2 Aprendizaje No Supervisado

4.2.1 Método del Codo

El análisis de inercia muestra una inflexión clara en $k=4$, donde la reducción marginal de varianza intracluster disminuye significativamente, justificando la selección de cuatro clusters como estructura óptima.

4.2.2 Segmentación Obtenida

- **Cluster 0:** Valor medio en tiempo en sitio, alto en páginas visitadas, bajo en historial, tasa de conversión moderada (0,802).
- **Cluster 1:** Valor máximo en tiempo en sitio y tasa de compra (0,826), valores medios en páginas y historial.
- **Cluster 2:** Valor mínimo en tiempo en sitio, medio en historial, tasa de conversión inferior (0,784).
- **Cluster 3:** Valores elevados en todas las métricas, especialmente páginas visitadas y historial, alta tasa de conversión (0,825).

4.2.3 Visualización Espacial

La representación bidimensional muestra clusters claramente diferenciados en el espacio de características, con centroides adecuadamente posicionados y separación nítida entre agrupaciones.

4.2.4 Interpretación

El análisis no supervisado revela cuatro perfiles distintivos de usuario con comportamientos coherentes: exploradores (cluster 0), compradores decisivos (cluster 1), compradores eficientes (cluster 2) y clientes leales (cluster 3). Esta segmentación natural proporciona una base sólida para estrategias diferenciadas, identificando particularmente los clusters 1 y 3 como segmentos de alto valor con diferentes patrones de navegación.

4.3 Aprendizaje por Refuerzo

4.3.1 Evolución del Aprendizaje

La curva de progreso muestra una mejora sustancial y continua desde recompensas iniciales cercanas a 4,0 hasta valores finales superiores a 7,0, evidenciando cuatro fases distintivas:

1. Exploración inicial rápida (episodios 0-1000)
2. Consolidación gradual (episodios 1000-4000)
3. Optimización avanzada (episodios 4000-8000)
4. Estabilización con fluctuaciones (episodios 8000-10000)

4.3.2 Distribución de Acciones

La política aprendida muestra una clara preferencia por:

- Productos Personalizados (48 %)
- Productos Populares (32 %)
- Estrategias minoritarias: Descuentos, Email y No Acción

En contraste, la política aleatoria distribuye acciones sin discernimiento estratégico, con predominio de Email (39 %) y distribución más uniforme entre las demás opciones.

4.3.3 Estrategias por Segmento

El análisis por segmento revela patrones altamente diferenciados:

- **Usuarios Nuevos:** Clara preferencia por Descuentos (valor $Q \approx 8,2$)
- **Usuarios Ocasionales:** Preferencia por Descuentos (6,4) y No Acción (3,7)
- **Usuarios Frecuentes:** Dominancia de Productos Populares (3,8)
- **Usuarios Premium:** Valores elevados para todas las estrategias, con ligera ventaja para Productos Personalizados (8,8)

4.3.4 Rendimiento Comparativo

La política aprendida alcanza una recompensa promedio de 6,98, superando significativamente a la política aleatoria (1,46), lo que representa una mejora del 378 %.

4.3.5 Interpretación

El algoritmo ha desarrollado estrategias contextuales sofisticadas adaptadas a cada segmento, reflejando principios de marketing intuitivos: incentivos económicos para usuarios nuevos, recomendaciones generales para usuarios frecuentes, y personalización para usuarios premium. La capacidad para optimizar decisiones secuenciales proporciona una ventaja competitiva sustancial frente a estrategias estáticas o no contextuales.

5 ANÁLISIS COMPARATIVO DE PARADIGMAS

5.1 Matriz Comparativa

Característica	Aprendizaje Supervisado	Aprendizaje No Supervisado	Aprendizaje por Refuerzo
Naturaleza	Predictivo - Inferencial	Descriptivo - Estructural	Prescriptivo - Decisional
Objetivo primario	Predecir variables objetivo	Descubrir estructura latente	Optimizar acciones secuenciales
Requisito de datos	Etiquetas/resultados conocidos	Sin etiquetas requeridas	Sistema de recompensas
Aplicación demostrada	Predicción de compras	Segmentación de usuarios	Estrategias de marketing
Métrica principal	ROC AUC	Coherencia e interpretabilidad	Recompensa acumulada
Resultado obtenido	0,786	4 segmentos interpretables	Mejora del 378 % vs. aleatorio
Fortaleza distintiva	Precisión predictiva	Descubrimiento no sesgado	Adaptabilidad contextual
Limitación principal	Requiere datos históricos etiquetados	No optimiza para objetivo específico	Complejidad computacional

Cuadro 1: Comparación de paradigmas de aprendizaje automático

5.2 Complementariedad Funcional

Los tres paradigmas abordan diferentes dimensiones del ciclo analítico:

1. **Aprendizaje No Supervisado** (Dimensión Descriptiva):
 - Proporciona comprensión estructural de la base de usuarios
 - Identifica patrones naturales sin imponer categorías preconcebidas
 - Establece fundamento para estrategias segmentadas
2. **Aprendizaje Supervisado** (Dimensión Predictiva):
 - Anticipa comportamientos futuros basados en patrones históricos
 - Cuantifica probabilidades de conversión según perfil de navegación
 - Permite priorización de leads según propensión a la compra
3. **Aprendizaje por Refuerzo** (Dimensión Prescriptiva):
 - Optimiza intervenciones basadas en contexto específico
 - Adapta estrategias según retroalimentación del entorno
 - Maximiza objetivos comerciales a largo plazo

5.3 Progresión Analítica

La implementación secuencial de estos paradigmas establece una progresión natural que potencia la estrategia comercial:

1. **Descubrir → Predecir → Optimizar**
2. **Preguntas abordadas secuencialmente:**
 - ¿Qué tipos de usuarios existen? (No Supervisado)
 - ¿Cuáles tienen mayor probabilidad de conversión? (Supervisado)
 - ¿Qué estrategia implementar con cada uno? (Refuerzo)
3. **Evolución de insights:**
 - De comprensión estructural
 - A anticipación comportamental
 - Hasta prescripción estratégica contextual

5.4 Integración Sinérgica

El verdadero potencial surge de la integración de los tres paradigmas en un ecosistema analítico cohesivo:

1. La segmentación no supervisada puede alimentar modelos supervisados específicos por cluster, mejorando precisión predictiva.
2. Las predicciones del modelo supervisado pueden enriquecer el espacio de estados del aprendizaje por refuerzo, incorporando probabilidades de conversión.
3. Las estrategias optimizadas por refuerzo pueden generar datos para entrenar modelos supervisados más precisos, estableciendo un ciclo virtuoso de mejora continua.

4. Esta integración proporciona un marco analítico integral para:
 - Comprender estructura de base de usuarios (descriptivo)
 - Anticipar comportamientos individuales (predictivo)
 - Optimizar intervenciones estratégicas (prescriptivo)

6 IMPLICACIONES ESTRATÉGICAS Y COMERCIALES

6.1 Derivadas del Aprendizaje Supervisado

1. **Optimización de experiencia de usuario:** Los coeficientes del modelo sugieren priorizar elementos que incrementen tiempo en sitio y navegación entre páginas.
2. **Scoring predictivo:** Implementación de sistema de calificación de usuarios según probabilidad de conversión para priorización de leads.
3. **Segmentación predictiva:** Clasificación binaria de usuarios en “alta” y “baja” probabilidad de conversión para estrategias diferenciadas.
4. **Optimización de retargeting:** Focalización en usuarios con alta probabilidad pero sin conversión reciente.

6.2 Derivadas del Aprendizaje No Supervisado

1. **Personalización por cluster:** Adaptación de interfaz y contenido según perfil de segmento.
2. **Desarrollo de productos:** Creación de ofertas específicas para necesidades de cada segmento.
3. **Optimización de adquisición:** Estrategias diferenciadas de captación según perfil de segmento objetivo.
4. **Análisis de transiciones:** Monitoreo de migración de usuarios entre segmentos como indicador de evolución comportamental.

6.3 Derivadas del Aprendizaje por Refuerzo

1. **Personalización contextual:** Implementación de sistema de recomendación adaptativo basado en segmento, historial e interés.
2. **Optimización multicanal:** Distribución eficiente de recursos entre canales según su efectividad contextual.
3. **Automatización de marketing:** Desarrollo de sistema decisional que seleccione automáticamente estrategias óptimas por contexto.
4. **Experimentación continua:** Mantener componente exploratorio para descubrir nuevas estrategias potencialmente efectivas.

6.4 Integración Estratégica

La combinación de los tres paradigmas posibilita una estrategia comercial holística:

1. **Segmentación dinámica:** Agrupación no supervisada actualizada periódicamente para reflejar evolución de patrones.
2. **Predicción contextual:** Modelos supervisados específicos por segmento para mayor precisión.
3. **Optimización adaptativa:** Estrategias de refuerzo personalizadas según segmento y probabilidad de conversión.
4. **Ciclo analítico continuo:** Retroalimentación constante entre paradigmas para refinamiento progresivo del ecosistema completo.

7 CONCLUSIONES Y RECOMENDACIONES

7.1 Hallazgos Principales

1. Los tres paradigmas de aprendizaje automático proporcionan perspectivas complementarias sobre el comportamiento del usuario, abarcando dimensiones descriptivas, predictivas y prescriptivas.
2. El aprendizaje supervisado logra una elevada capacidad predictiva (ROC AUC 0,786) con énfasis en minimizar falsos negativos (recall 0,946).
3. El aprendizaje no supervisado identifica cuatro segmentos naturales con perfiles comportamentales y valores comerciales diferenciados.
4. El aprendizaje por refuerzo desarrolla estrategias contextuales sofisticadas, cuadruplicando el rendimiento frente a enfoques aleatorios.
5. La integración sinérgica de los tres paradigmas establece un marco analítico integral superior a implementaciones aisladas.

7.2 Recomendaciones

1. Implementación secuencial:

- Comenzar con análisis no supervisado para establecer segmentación base
- Desarrollar modelos predictivos específicos por segmento
- Implementar gradualmente optimización por refuerzo en áreas prioritarias

2. Infraestructura técnica:

- Desarrollar arquitectura que permita procesamiento en tiempo real
- Implementar sistema de reentrenamiento periódico de modelos
- Establecer métricas de monitoreo para cada paradigma

3. Aplicaciones prioritarias:

- Sistema de recomendación de productos personalizado
- Optimización dinámica de descuentos según contexto
- Selección automática de canal de comunicación óptimo

4. Experimentación continua:

- Mantener componente exploratorio en sistema de refuerzo
- Evaluar periódicamente número óptimo de clusters
- Probar variables predictoras adicionales en modelos supervisados

7.3 Consideraciones Finales

La implementación integrada de los tres paradigmas de aprendizaje automático constituye un enfoque analítico holístico con potencial transformador para estrategias de marketing digital. La complementariedad funcional entre comprensión estructural (no supervisado), anticipación comportamental (supervisado) y optimización contextual (refuerzo) proporciona un marco comprehensivo para maximizar valor comercial.

El presente caso de estudio demuestra que incluso implementaciones relativamente sencillas de cada paradigma producen resultados significativos, sugiriendo que implementaciones más sofisticadas (redes neuronales, clustering jerárquico, aprendizaje profundo por refuerzo) podrían amplificar aún más su impacto estratégico.

La evolución hacia sistemas analíticos integrados que combinan estos tres paradigmas representa la vanguardia en optimización comercial basada en datos, proporcionando ventajas competitivas sustanciales para organizaciones que implementen estos enfoques de manera efectiva.

ANEXO: GLOSARIO TÉCNICO

- **ROC AUC:** Área bajo la curva de característica operativa del receptor, métrica de rendimiento para clasificación binaria.
- **K-Means:** Algoritmo de clustering que minimiza la suma de distancias cuadradas entre puntos y centroides.
- **Método del Codo:** Técnica para determinar número óptimo de clusters mediante análisis de inercia.
- **Q-Learning:** Algoritmo de aprendizaje por refuerzo que aprende valores de utilidad para pares estado-acción.
- **Política epsilon-greedy:** Estrategia que balancea exploración y explotación mediante selección probabilística.
- **Matriz de Confusión:** Tabla que cuantifica aciertos y errores de un modelo clasificador binario.
- **Recall:** Proporción de casos positivos correctamente identificados (sensibilidad).
- **Precision:** Proporción de predicciones positivas correctas entre todas las predicciones positivas.